



Politechnika Wrocławska

Projekt Sieci Neuronowe i Neurosterowniki Analiza klasyfikacji obrazów radiograficznych płuc

Imię, nazwisko, numer albumu

Eryk Wójcik, 259311

Michał Stanisławski 259231

Aleksander Łuczycki, 259302

Prowadzący


Dr inż. Piotr Ciskowski

Termin oddania

20 czerwca 2023

1 Wstęp

Raport przedstawia proces klasyfikacji obrazów rentgenowskich płuc przy użyciu modelu głębokiego uczenia maszynowego. Nasz zbiór danych zawiera trzy klasy: 'Covid', 'Normal' i 'Viral Pneumonia'. Celem tego procesu jest zidentyfikowanie, czy pacjent jest zdrowy, ma zapalenie płuc czy covid.



Rysunek 1: Przykładowe dane wejściowe

2 Wczytanie i przygotowanie danych

W pierwszej kolejności, wczytujemy obrazy korzystając z funkcji `imread` z biblioteki `OpenCV`. Wyświetlamy przykładowe obrazy z każdej z kategorii, aby zobaczyć różnice między klasami.

Następnie wczytujemy dane do naszego modelu za pomocą funkcji `ImageDataGenerator` i `flow_from_directory` z biblioteki `keras`. Dane są przeskalowane (`rescale = 1. / 255`), a także zastosowane są różne augmentacje, takie jak obrót (`rotation_range = 20`), przekształcenia ściszenia (`shear_range = 0.2`) i losowe odbicia horyzontalne (`horizontal_flip = True`), co ma na celu spowolnienie przeuczenia i dodanie dodatkowego "szumu" do zbioru danych.

3 Konstrukcja modelu

Wykorzystujemy architekturę modelu `VGG19`, która jest popularnym modelem dla problemów klasyfikacji obrazów. Model ten jest pre-trenowany na zbiorze danych `ImageNet`. Do modelu wprowadzamy fine-tuning - wszystkie warstwy oprócz ostatnich dwóch zostają zamrożone, w celu bardziej szczegółowego dopasowania sieci.

Nasza sieć neuronowa składa się z podstawowego modelu `VGG19`, po którym następuje warstwa `Flatten` przekształcająca tensor 2D na wektor 1D, a na końcu znajduje się warstwa `Dense` z funkcją aktywacji `softmax`, która będzie generować prawdopodobieństwa dla naszych trzech klas.

Do kompilacji modelu używamy optymalizatora `Adam` z `learning rate 0.0001`, funkcji straty `'categorical_crossentropy'` i metryki `'accuracy'`.

Cross-Entropy

$$D(\hat{Y}, Y) = -\frac{1}{N} \cdot \sum Y_i \cdot \log(\hat{Y}_i)$$

$$\begin{matrix} Y = [1, 0, 0] \\ \hat{Y} = [0.7, 0.2, 0.1] \end{matrix} \rightarrow D(\hat{Y}, Y) = \mathbf{0.35}$$

$$\begin{matrix} Y = [1, 0, 0] \\ \hat{Y} = [0.1, 0.3, 0.6] \end{matrix} \rightarrow D(\hat{Y}, Y) = \mathbf{2.30}$$

Rysunek 2: Przedstawienie działania algorytmu categorical crossentropy

4 Inne testowane przez nas modele

4.1 MobileNetV2

MobileNetV2 to lekka sieć neuronowa, zaprojektowana specjalnie z myślą o urządzeniach o ograniczonej mocy obliczeniowej, takich jak smartfony czy małe komputery. Jest to model wysoce skuteczny dla problemów klasyfikacji obrazów, który potrafi osiągnąć bardzo dobrą precyzję, jednocześnie zużywając niewielką ilość zasobów. MobileNetV2 jest charakterystyczny dla swojej architektury opartej na odwróconych blokach konwolucyjnych, które składają się z warstwy rozszerzającej, warstwy głębokiej konwolucji i warstwy konwolucji zwężającej.

4.2 ResNet50

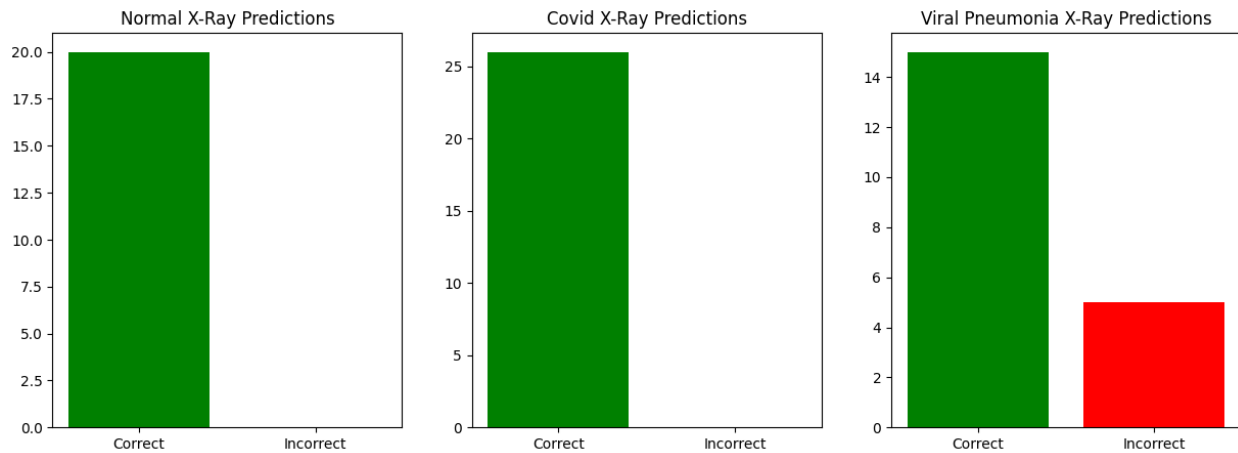
ResNet50, skrót od Residual Network, jest jednym z popularnych modeli stosowanych w problemach klasyfikacji obrazów. Model składa się z 50 warstw, w tym 48 warstw konwolucyjnych, 1 warstwy gęstej i 1 warstwy wyjściowej. Kluczowym elementem tej sieci jest zastosowanie połączeń rezydualnych, które pomagają w uniknięciu problemu zanikającego gradientu, co jest typowym problemem w głębokich sieciach neuronowych. Połączenia te umożliwiają przekazanie wejścia bezpośrednio do wyższych warstw, co pomaga modelowi nauczyć się różnicy (residual) między warstwami, zamiast uczyć się bezpośrednio oczekiwanego wyniku.

5 Trenowanie modelu

Model jest trenowany na danych treningowych z użyciem funkcji fit. Używamy również walidacji na danych walidacyjnych i stosujemy wczesne zatrzymywanie (EarlyStopping) dla uniknięcia przeuczenia modelu. Zapisujemy najlepsze wagi modelu na podstawie straty walidacyjnej.

6 Ewaluacja modelu

Po wytrenowaniu modelu, przewidujemy etykiety dla danych testowych. Następnie obliczamy dokładność klasyfikacji i tworzymy wykresy porównujące prawdziwe i przewidywane etykiety.



Rysunek 3: Wynik działania modelu

7 Wnioski

- Model VGG19 może być skutecznie wykorzystany do klasyfikacji obrazów radiograficznych płuc. Pozostałe testowane modele gorzej sobie radziły z uczeniem.
- Nasz model dobrze sobie radzi z klasyfikacją covidu, ale kilka obrazów pacjentów chorych na zapalenie płuc sklasyfikował jako zdrowe.



Rysunek 4: Koniec.